LAB03 · LABORATÓRIO DE EXPERIMENTAÇÃO DE SOFTWARE

Velocidade e estabilidade em projetos open-source: mineração das métricas DORA no GitHub

300 repositórios populares · janela de 01/10/2025 a 30/09/2026

Pedro · Enrico Bessa · Péricles Pires

Engenharia de Software · 6º período

O problema: o GitHub não registra deploys

As métricas DORA são o padrão de mercado para medir entrega de software, mas precisam de dados que não são públicos.

MÉTRICA DORA	O QUE MEDE	PROXY NO GITHUB
Deployment frequency	Com que frequência vai para produção	Releases publicadas por semana
Lead time for changes	Do commit até produção	Data da release − data do commit
Change failure rate	Deploys que causam falha	(a) CI com falha · (b) release seguida de correção
Tempo de recuperação	Quanto leva para se recuperar	Da primeira falha de CI ao próximo sucesso

A pergunta deixa de ser só *"qual é o valor da métrica?"* e passa a ser também **"o quanto podemos confiar nele?"**

Questões de pesquisa

Hipóteses escritas antes de ver os dados (Sprint 1).

RQ	PERGUNTA
01 – 04	Qual a frequência de deploy, o lead time, a taxa de falha e o tempo de recuperação?
05	Repositórios com mais deploys falham mais ou menos?
06	Que características (linguagem, estrelas, contribuidores, idade) se associam a melhor desempenho?
07	A classificação DORA de um repositório muda se mudarmos a definição operacional?
08 (bônus)	Deployment rework rate: proporção de releases que são correções

Pipeline de coleta próprio

Um único comando: `python -m pipeline --config config.yaml` — sem bibliotecas prontas da API do GitHub.



323

testes automatizados (pytest), 100% de cobertura no módulo de métricas, rodando no GitHub Actions

22.100

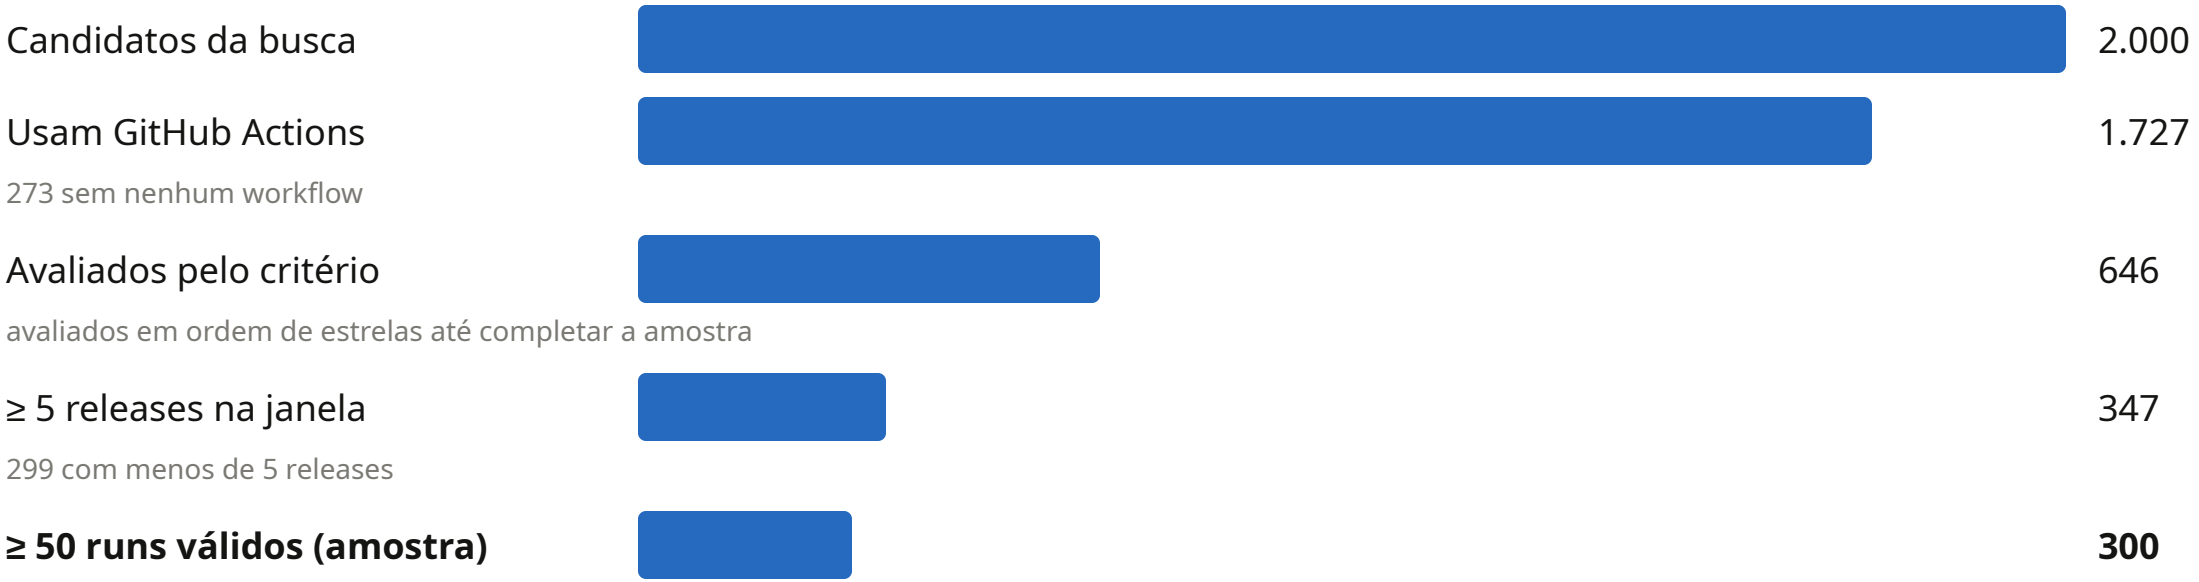
releases na janela e mais de 477 mil workflow runs a processar

0

chamadas repetidas: cache em disco e retomada automática após qualquer interrupção

Funil de seleção

Gerado automaticamente pelo pipeline (`resultados/funil_selecao.md`).



A amostra

300 dos repositórios mais estrelados do GitHub que usam CI/CD e publicam releases.

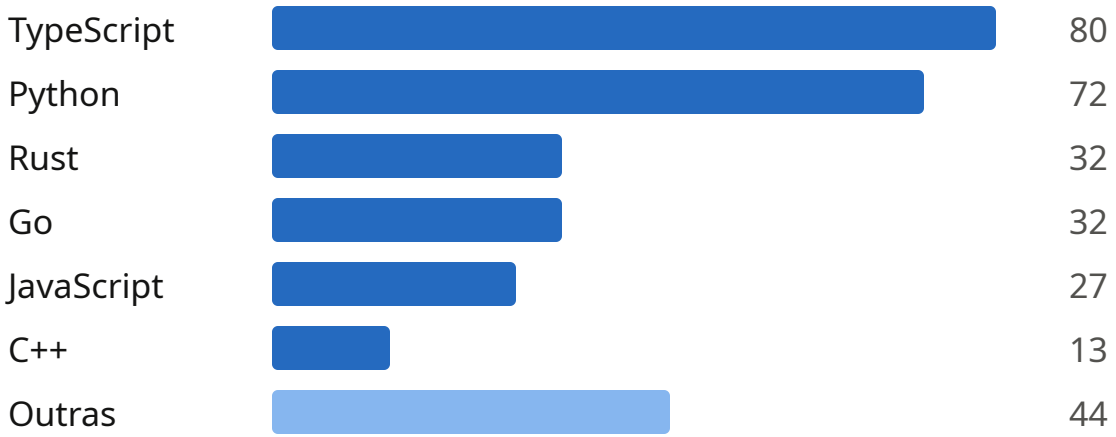
63.734
estrelas (mediana) · Q1 49 mil, Q3 92 mil

473
contribuidores (mediana) · Q1 222, Q3 1.066

6,2 anos
idade mediana · 49 repositórios criados dentro da janela

28
releases na janela (mediana) · máximo de 2.584

Linguagem principal



Metodologia

Definições operacionais e variantes

Mesmas regras para toda a turma; variantes obrigatórias para medir a sensibilidade.

Lead time (RQ 02)

(a) por release: release − commit mais antigo dela.
(b) por commit: mediana de todos os commits.
Um commit "esquecido" faz (a) explodir e quase não mexe em (b).

Change failure rate (RQ 03)

(a) CI: falhas ÷ (falhas + sucessos); `cancelled` ignorado.
(b) entrega: release seguida, em até 7 dias, por uma release corretiva (patch-only no SemVer ou maioria dos commits com fix/revert/hotfix).

Tempo de recuperação (RQ 04)

Por workflow: da primeira falha após um sucesso até o próximo sucesso. Falhas não recuperadas até o fim da janela são **censuradas** e contadas, não descartadas.

Combinações da RQ 07

C1: release · lead (a) · CFR (a)
C2: release + pré-release · lead (b) · CFR (b)
C3: tag · lead (b) · CFR (a)

Desafios técnicos e decisões

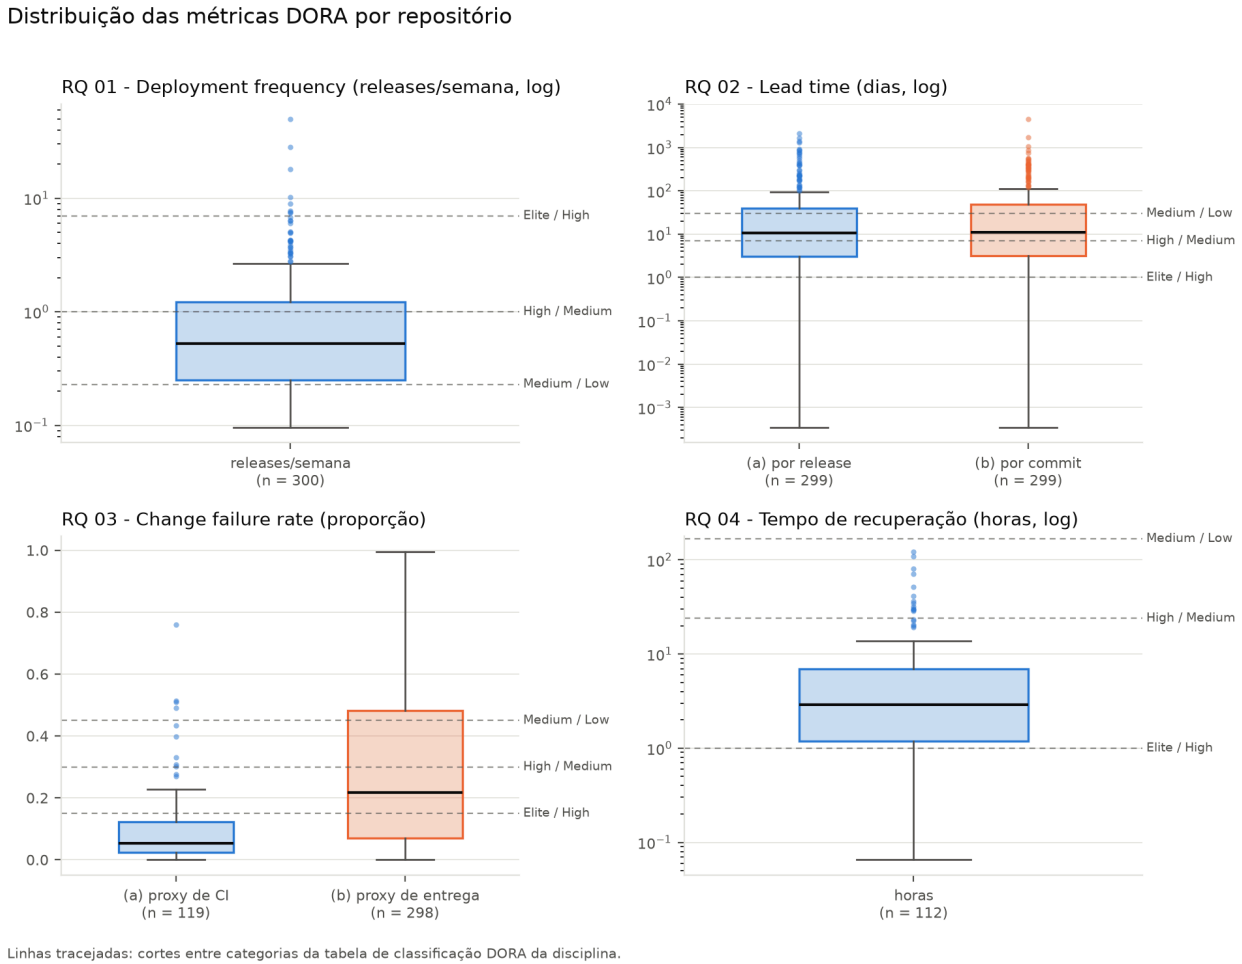
O que a API não entrega pronto, e como resolvemos.

- **Teto de 1.000 runs por consulta** → janela fatiada por mês; mês cheio é dividido ao meio até caber. 130 repositórios estavam no teto.
- **Tags não têm data** → API GraphQL, que lista as tags já ordenadas pela data do commit.
- **Release anterior fora da janela** → usada como base do compare (bug encontrado pelos testes e corrigido).
- **Coleta lenta** → cache de compares compartilhado entre variantes e 8 repositórios em paralelo: de ~30 h estimadas para ~9 h.
- **Rate limit e quedas de rede** → espera automática pela renovação da cota e backoff exponencial (1, 2, 4, 8, 16 s).
- **Workflows que começam a janela falhando** → início do episódio desconhecido: contados à parte (decisão do grupo).

RQ 01 – 04

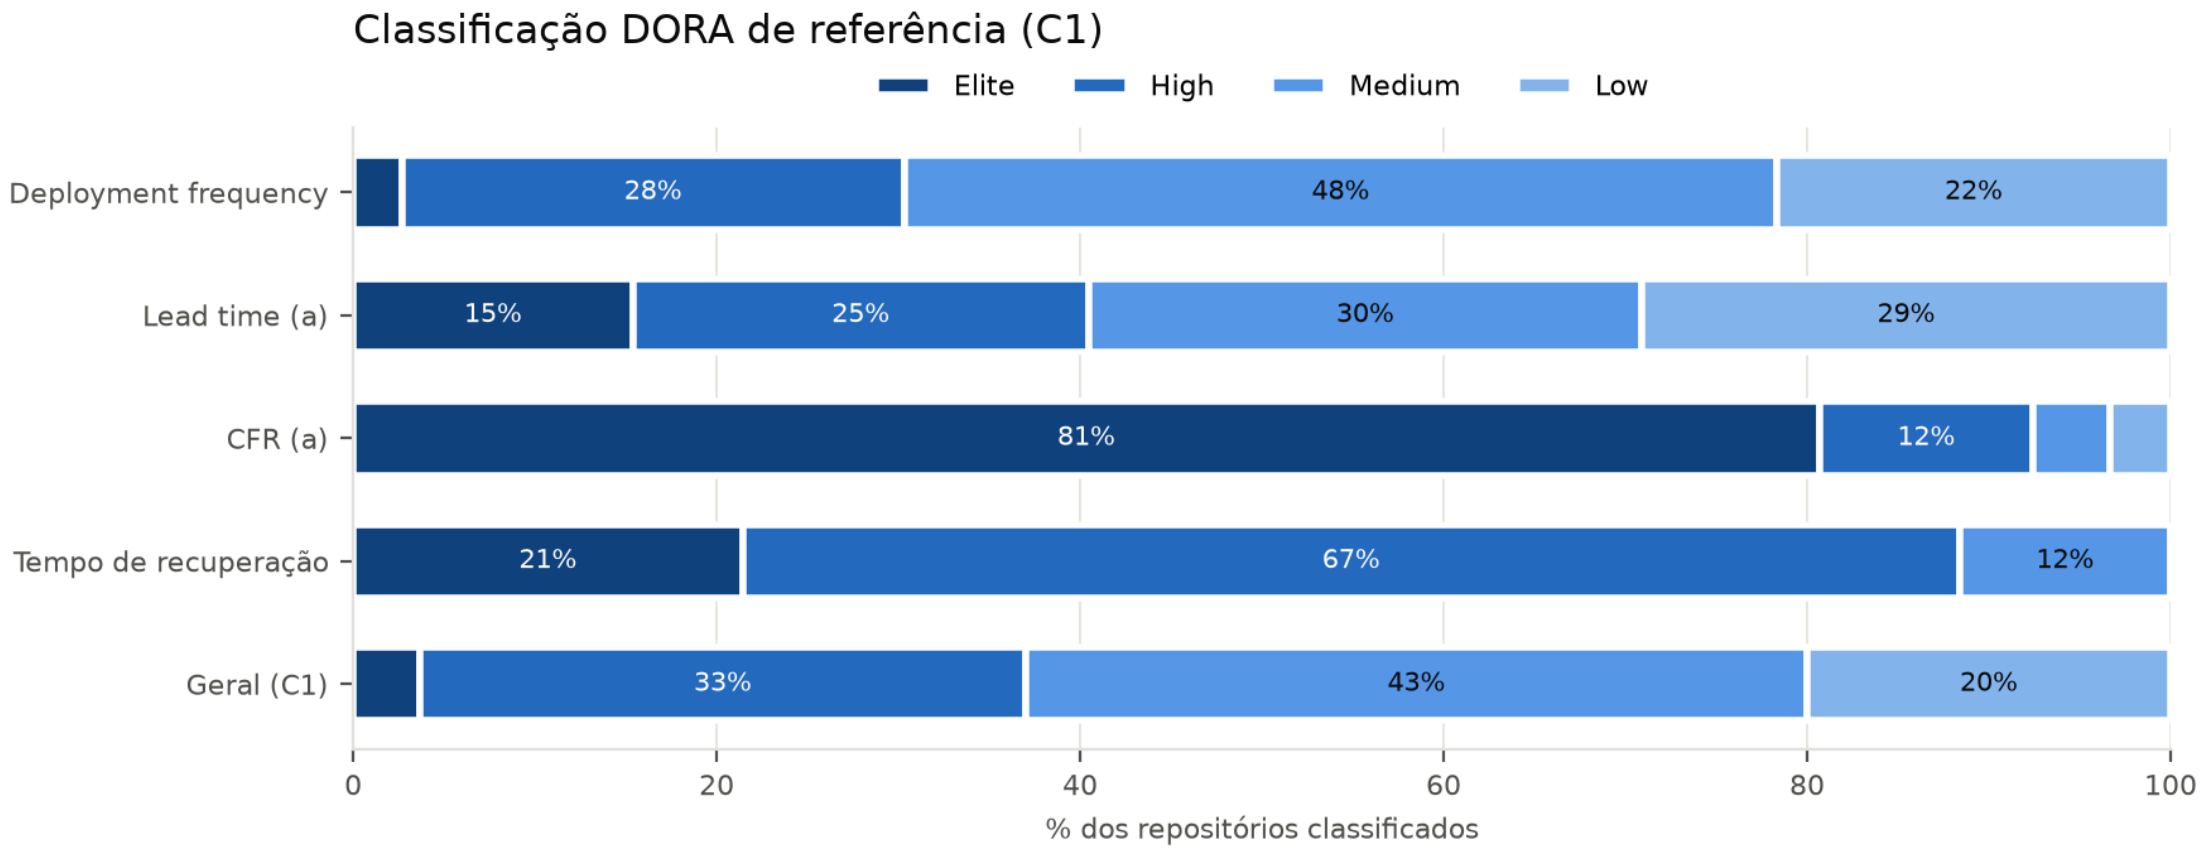
Distribuição das métricas

Preliminar: CFR (a) e recuperação com os 119 repositórios cujos workflow runs já foram coletados.



RQ 01 – 04

Classificação DORA de referência (C1)

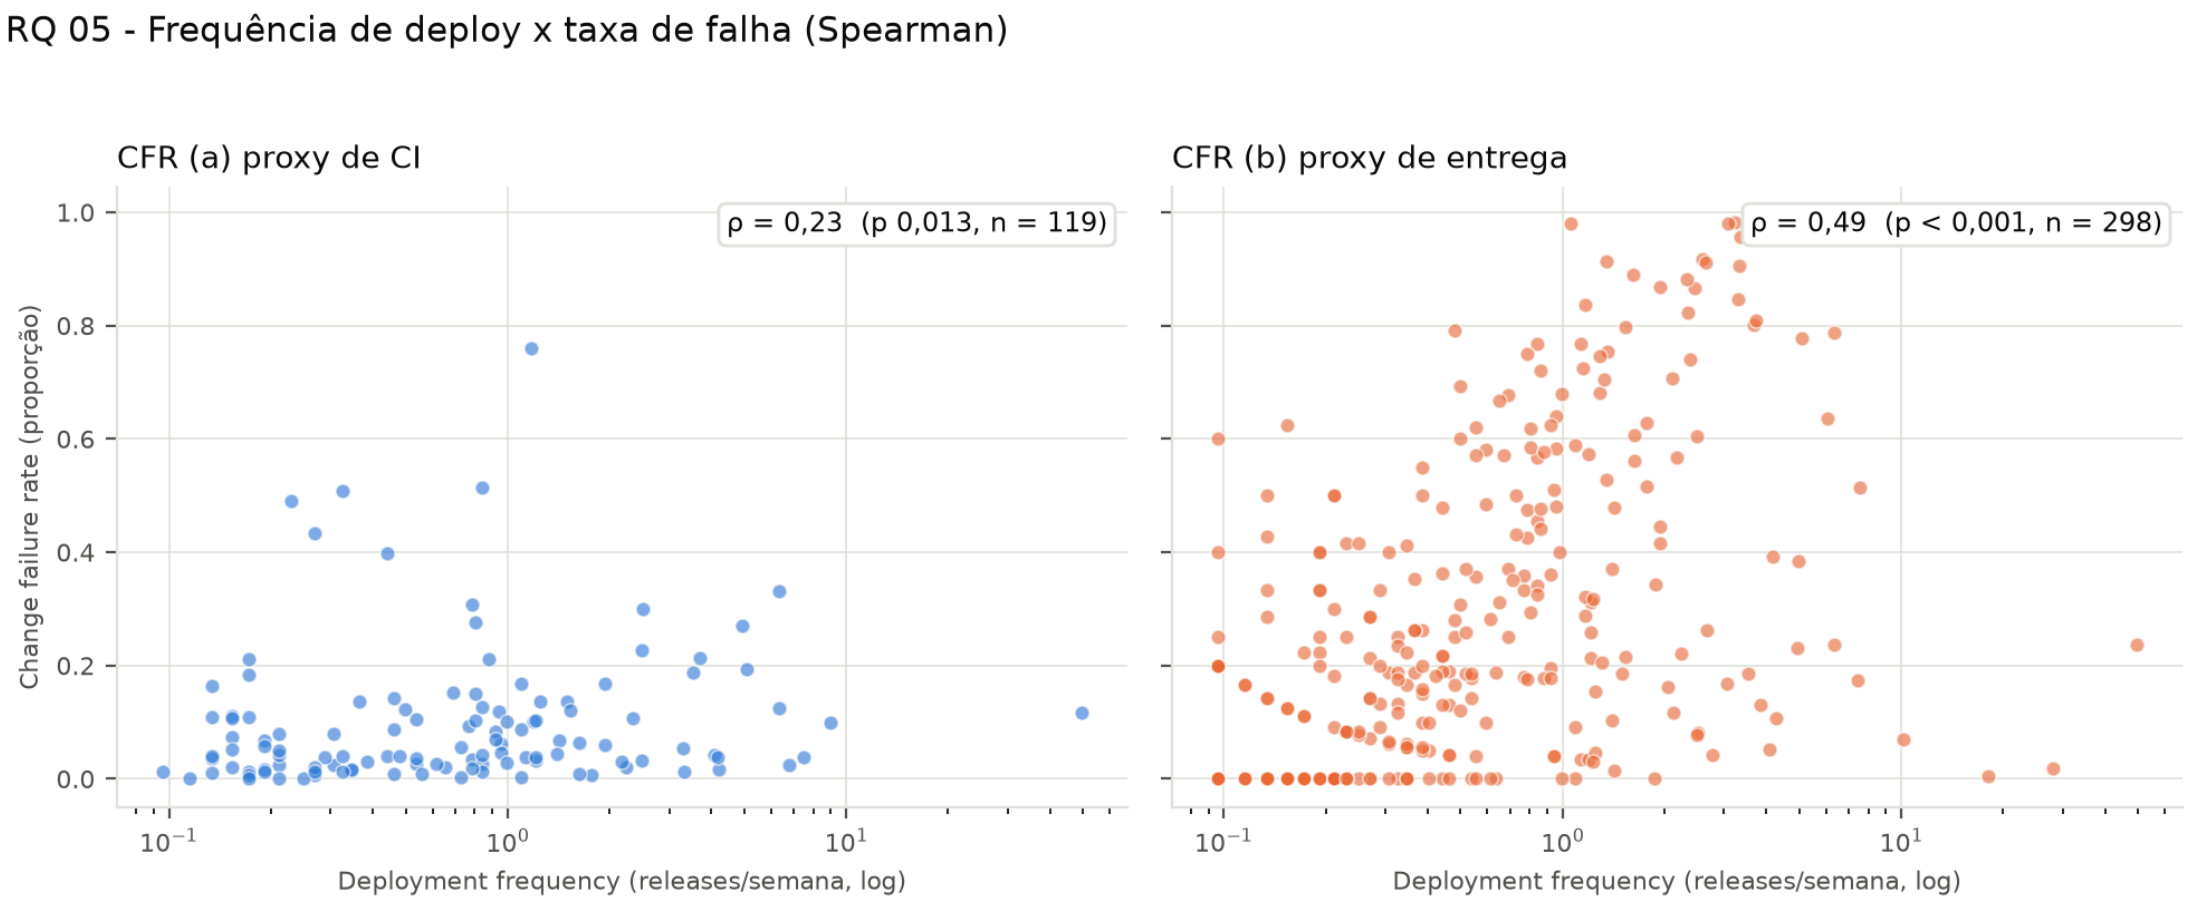


resultados/rq01_04/classificacao_c1.md

RQ 05

Velocidade × estabilidade

CFR (a): ρ = 0,23 (fraca, n = 119) · CFR (b): ρ = 0,49 (moderada, n = 298) — correlação ≠ causalidade.

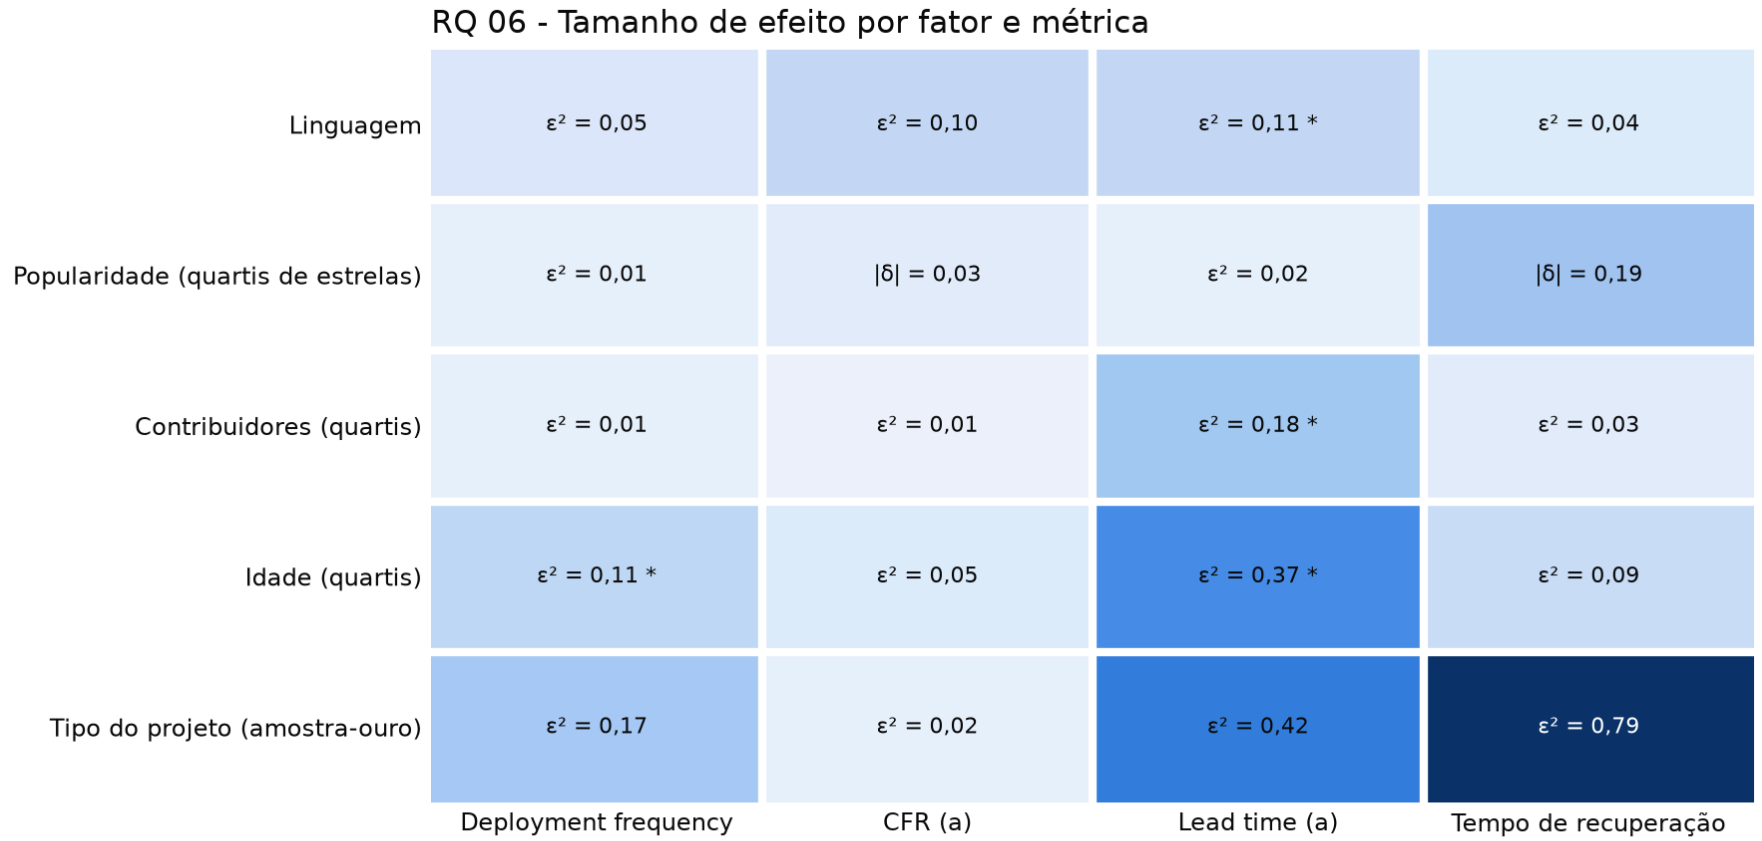


resultados/rq05/spearman.md

RQ 06

O que se associa a melhor desempenho

20 testes com correção de Holm. A idade domina: repositórios jovens têm lead time de 2 dias; os antigos, de 43.



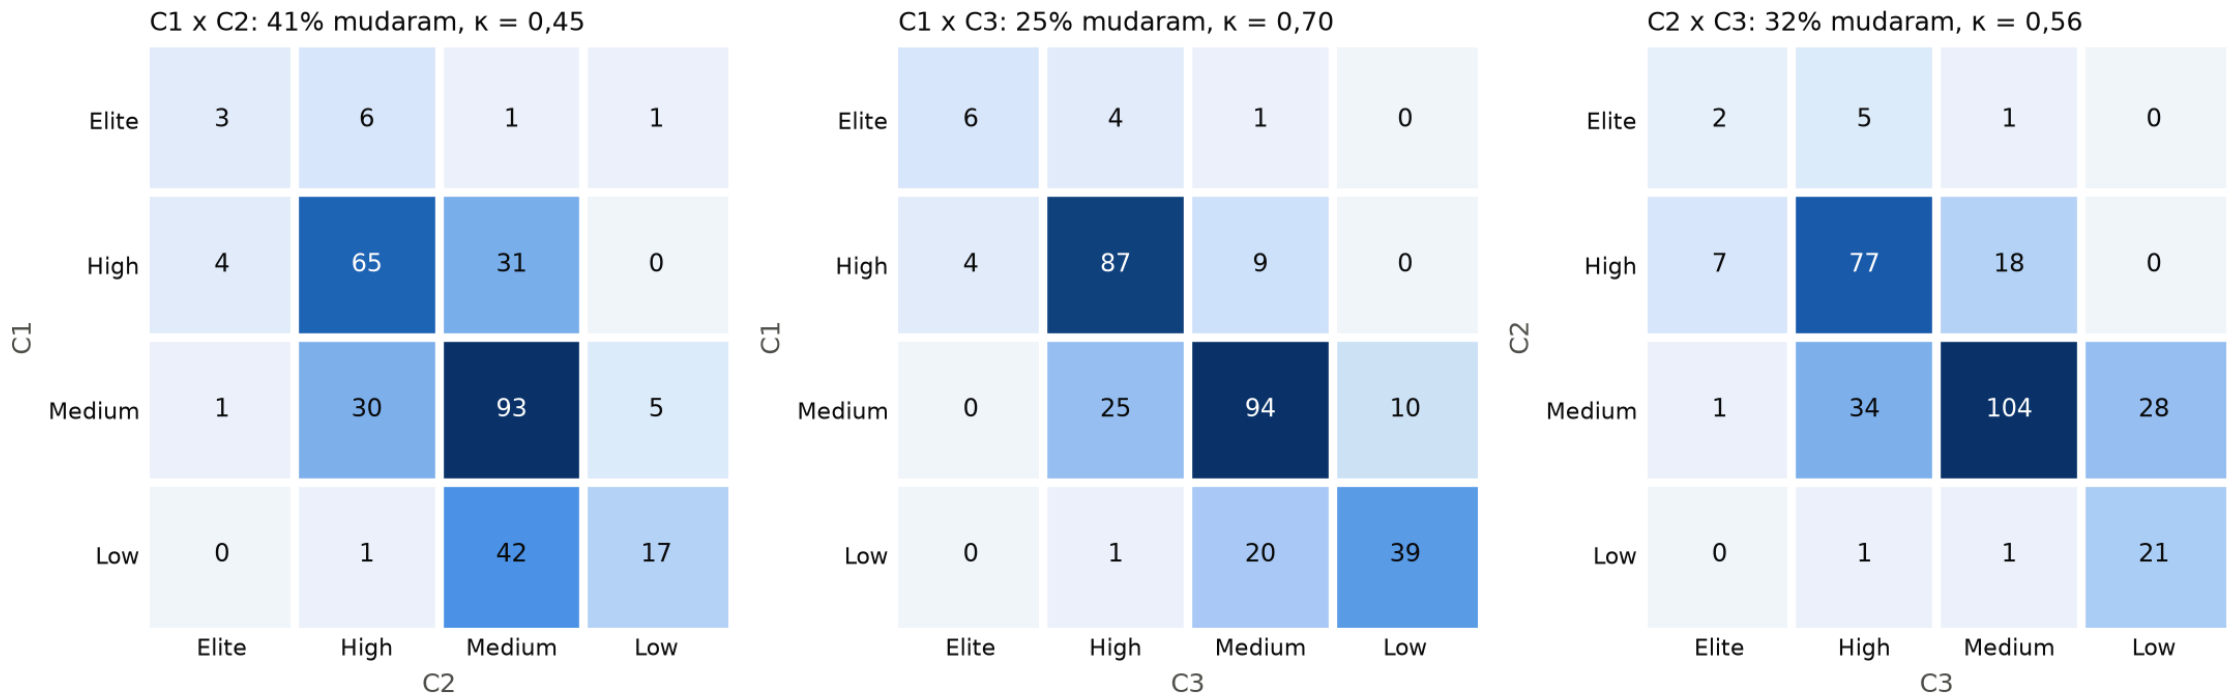
* significativo a 5% após a correção de Holm. ε²: Kruskal-Wallis; |δ|: Cliff (2 grupos).

resultados/rq06/testes.md · medianas.md

RQ 07

A classificação depende da definição?

25% a 41% dos repositórios mudam de categoria (κ ponderado 0,45–0,70). Aproximação preliminar: lead time e CFR (b) de C2/C3 calculados por release.

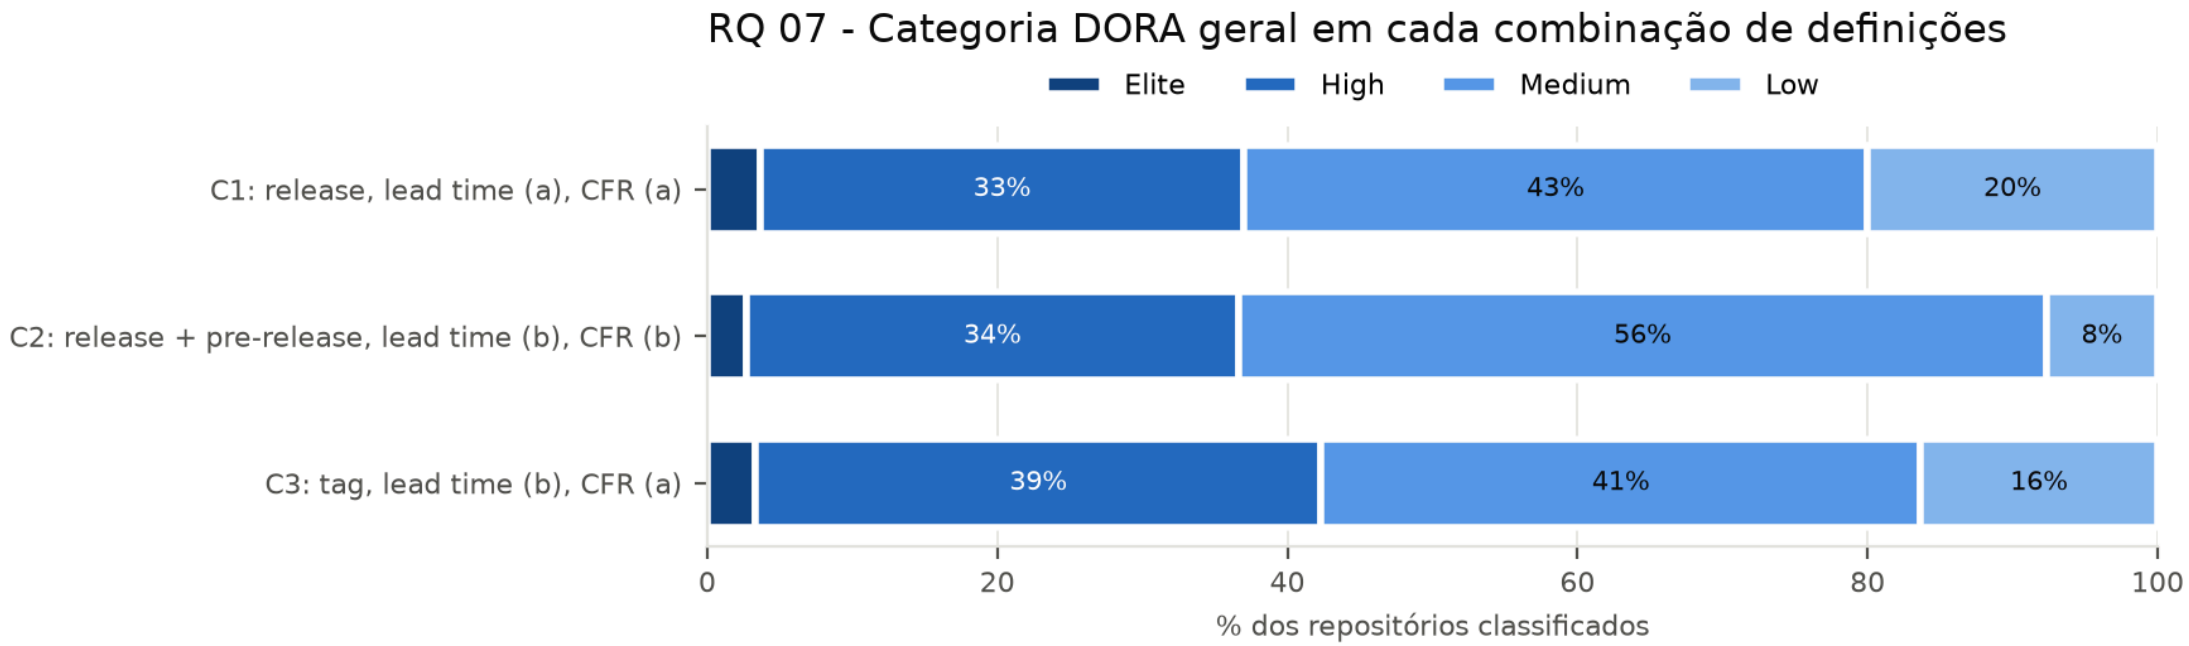


resultados/rq07/concordancia.md

RQ 07

Categoria geral em cada combinação

O que mais muda a classificação é a definição do CFR (62% mudam) e do lead time (41%) — não a unidade de deploy (11–25%).



Validação manual da heurística

A heurística "release corretiva" sustenta o CFR (b) e o rework rate — o quanto ela erra?

- Sorteio reproduzível (semente 42) de **20 repositórios** e **5 releases** de cada: 100 releases.
- Rotulagem manual com página própria: release notes e commits lado a lado, **sem mostrar a resposta da heurística**.
- Mede-se precisão, recall e F1, com intervalo de confiança por bootstrap.

Adaptação autorizada pelo professor: 20 repositórios em vez de 60 e rótulos produzidos por IA (Claude), sem acesso à saída da heurística — portanto sem kappa de Fleiss.

HEURÍSTICA	MARCADAS	P	R	F1
v1: patch *ou* algum commit "fix"	93	0,49	0,98	0,66
v2: patch *ou* maioria "fix"	52	0,62	0,68	**0,65**

47 das 100 releases são corretivas pela referência. Nenhuma variante chegou a F1 ≥ 0,70: o sinal mais forte está nas release notes, que o pipeline não coleta (trabalho futuro).

Ameaças à validade

Construto

Release ≠ deploy (bibliotecas). Falha de CI ≠ falha em produção. Heurística de correção com F1 = 0,65. Rebase e squash alteram a data do commit.

Interna

49 repositórios criados dentro da janela. Workflows auxiliares (docs, lint) pesam como testes. Censura de episódios e releases.

Externa

Só repositórios muito populares (> 41 mil estrelas) e ativos; não representam projetos corporativos, contexto das pesquisas DORA.

Conclusão

16 testes na RQ 06 (Holm reduz o poder). Linguagens raras agrupadas. RQ 05 é correlacional.

Conclusões e próximos passos

Principais achados

- Perfil típico: ~1 release a cada 2 semanas, lead time de ~11 dias e recuperação de CI em ~3 h — **Medium** na classificação geral (43%); só 4% Elite.
- A métrica depende do proxy: CFR de CI ≈ 5%, CFR de entrega ≈ 22%.
- Quem publica mais tem CFR (b) maior (ρ = 0,49) — em boa parte efeito da própria definição.
- Repositórios mais jovens entregam mais rápido (efeito grande no lead time).
- A classificação é sensível à definição: até 41% mudam de categoria.

Próximos passos

- Heurística de correção baseada nas release notes (F1 atual 0,65)
- Replicação cruzada do pipeline por outro grupo
- Artigo completo no template SBC

Código, dados e GitHub Projects:
github.com/PedroL10/Laboratorios