Relatório — LAB04: testes de hipótese por dentro

- **Par de testes:** t de Welch × Mann-Whitney (P1)
- **Dashboard:** https://pedrol10.github.io/Laboratorios/
- **Repositório:** https://github.com/PedroL10/Laboratorios/tree/master/LAB04
- **GitHub Projects:** https://github.com/users/PedroL10/projects/6

Resumo

O estudo compara o t de Welch e o Mann-Whitney em um cenário de Engenharia de Software: o tempo até o merge de pull requests (PRs) antes e depois da adoção de um bot de revisão de código. Uma amostra real de 60 PRs do projeto HPX calibrou uma simulação de 10.000 repetições por configuração, que mediu o erro tipo I e o poder de cada teste.

Com dados parecidos com os reais, os dois testes mantêm o erro tipo I perto de 5%, e o **t de Welch tem mais poder** (74% contra 65% quando o tempo dobra). Isso contrariou a expectativa do grupo, que apostava no Mann-Whitney. A vantagem só passa para o Mann-Whitney quando os dados têm cauda muito pesada. Nos dados reais, o t de Welch rejeitou H_0 ($p = 0{,}046$) e o Mann-Whitney não ($p = 0{,}077$). **Recomendamos o t de Welch** para este cenário.

1. Cenário

Pergunta: o tempo até o merge dos PRs do HPX mudou depois que o projeto adotou o bot de revisão CodeRabbit?

	t de Welch	Mann-Whitney
H_0	As médias do tempo até o merge são iguais antes e depois do bot.	Um PR de um período tem a mesma chance de demorar mais ou menos que um PR do outro.
H_1	As médias são diferentes.	Os PRs de um período tendem a demorar mais que os do outro.

- **Teste bicaudal, com $\alpha = 0{,}05$.** O bot pode acelerar o merge, porque antecipa parte da revisão, ou atrasá-lo, porque gera comentários que o autor precisa responder.
- **O que cada teste compara:** o t de Welch compara médias, sem supor variâncias iguais. O Mann-Whitney compara postos, ou seja, a posição de cada PR quando todos os tempos são ordenados.

2. Dados reais

Coleta

Item	Valor
Repositório	TheHPXProject/hpx, biblioteca C++
Bot	CodeRabbit, que passou a atuar de forma contínua em julho de 2026
Grupo sem bot	30 PRs abertos de março a maio de 2026, sem atuação do bot
Grupo com bot	30 PRs abertos de julho a setembro de 2026, com review ou comentário do bot
Fonte	API de busca do GitHub, com sorteio de 30 PRs por grupo usando a semente 42
Data da coleta	05/11/2026

Critérios aplicados aos dois grupos:

- **Somente PRs mergeados e de autores humanos.** PRs abertos por bots, como o Dependabot, ficaram de fora.
- **Sem review do Copilot.** Esse outro bot atua nos dois períodos e confundiria a comparação.
- **Merge em até 30 dias.** Os PRs de setembro só tiveram 36 dias para serem mergeados até a coleta. Sem esse limite, o período antigo teria mais tempo para acumular PRs demorados.
- **Junho de 2026 fora.** É o mês de transição, com PRs que receberam o bot quando já estavam em andamento.

Durante a seleção, 67 dos 103 PRs que pareciam não ter revisão do bot tinham comentário dele. Por isso, o grupo sem bot exige **nenhuma** atuação do CodeRabbit. Uma conferência direta de 24 PRs da amostra na API confirmou que todos estavam no grupo certo.

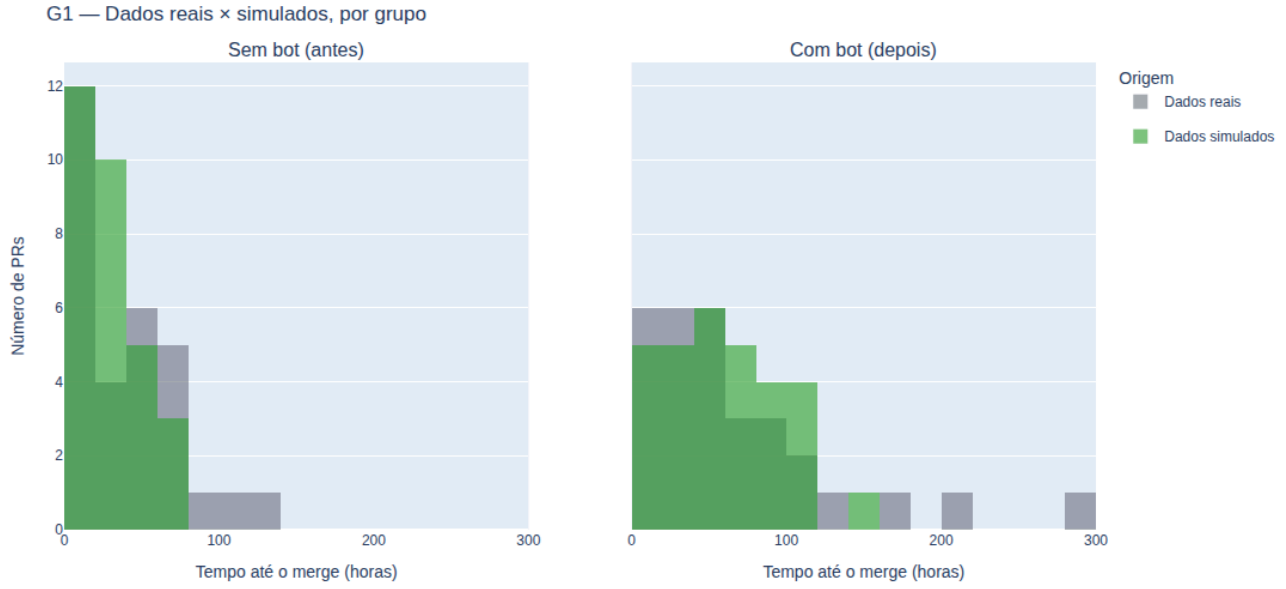
Forma da distribuição

Medida	Sem bot	Com bot
Média	40,4 h	68,0 h
Mediana	39,1 h	45,1 h
Desvio padrão	34,0 h	65,5 h
Assimetria	0,93	1,86
Outliers (Tukey)	0	1
Shapiro-Wilk (p)	0,018	0,0002

Diferença de AIC para o melhor ajuste de cada grupo (0 é o melhor):

Distribuição	Sem bot	Com bot	Todos
Gamma	0,2	0,0	0,0
Weibull	0,0	0,3	0,0
Lognormal	6,4	0,1	7,2
Normal	14,1	22,7	48,1

Os dados não são normais: a assimetria é positiva, e o Shapiro-Wilk rejeita a normalidade nos dois grupos. A Gamma e a Weibull empatam como melhores ajustes, com forma perto de 1, ou seja, próximas de uma exponencial. A lognormal, sugerida como exemplo no enunciado, ajustou pior no grupo sem bot.



G1. Os dados simulados, gerados pelo melhor ajuste de cada grupo, reproduzem a assimetria dos dados reais.

3. Método da simulação

Item	Escolha
Distribuição base	Gamma ajustada à amostra inteira (forma 1,07; escala 50,59 h)
H_0 verdadeira	Os dois grupos vêm da mesma Gamma
Efeito	Os tempos do grupo com bot são multiplicados por um fator: 1; 1,25; 1,5; 1,75; 2 e 2,5
Repetições	10.000 por combinação de situação e fator
Semente	42, em um único gerador do NumPy

O efeito é multiplicativo porque, nos dados reais, o desvio padrão cresce junto com a média, e o coeficiente de variação fica parecido nos dois grupos (0,84 e 0,96). Nos dados reais, a média com bot é 1,68 vez a média sem bot.

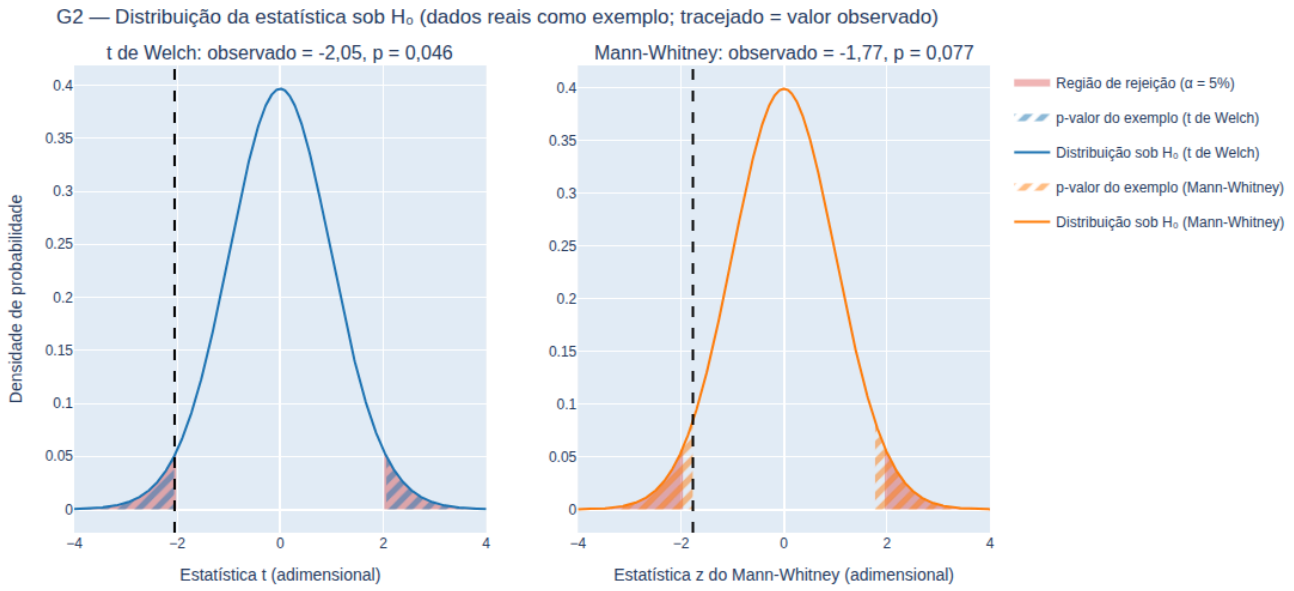
Situações simuladas, sendo as duas últimas violações dos pressupostos do t de Welch:

Situação	Distribuição	n por grupo	O que viola
Ajuste real	Gamma (forma 1,07; escala 50,59 h)	30	Nada: é a referência
Amostra pequena	A mesma Gamma	10	A aproximação usada pelo t de Welch fica pior com poucos dados
Cauda pesada	Lognormal (σ do log = 2,5; mediana 41,8 h)	30	Assimetria e outliers bem mais extremos que os reais

Expectativa registrada antes das simulações de poder:

- **Erro tipo I:** os dois testes perto de 5%, com o t de Welch conservador na cauda pesada.
- **Poder:** o Mann-Whitney com mais poder, porque os dados são assimétricos.
- **Cauda pesada e amostra pequena:** a vantagem do Mann-Whitney seria maior com cauda pesada e menor com amostra pequena.

4. Como os testes funcionam



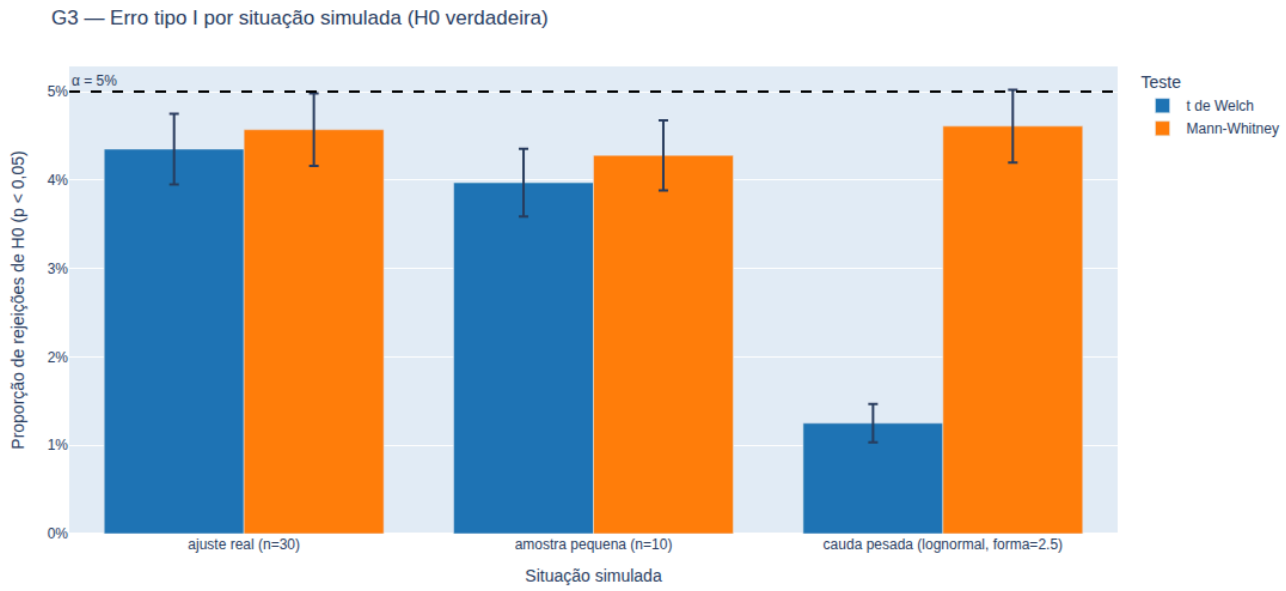
G2. Sob H_0, a estatística t do Welch segue uma t de Student com 43,6 graus de liberdade, e o z do Mann-Whitney segue, aproximadamente, uma normal padrão. A região de rejeição são as duas caudas que somam 5%: $|t| > 2{,}02$ e $|z| > 1{,}96$. O exemplo são os dados reais. O t de Welch caiu dentro da região de rejeição ($t = -2{,}05$, $p = 0{,}046$), e o Mann-Whitney ficou fora dela ($z = -1{,}77$, $p = 0{,}077$).

O **p-valor** é a área hachurada: a chance de ver uma diferença pelo menos tão grande **se H_0 fosse verdadeira**. Ele **não** é a probabilidade de H_0 ser verdadeira, nem o tamanho do efeito.

Os testes aplicados a um conjunto simulado. Em um conjunto gerado pelos ajustes de cada grupo, em que as médias realmente diferem, os dois testes rejeitaram H_0:

Teste	Estatística	p-valor	Interpretação
t de Welch	t = −4,31	0,0001	Médias simuladas de 27,2 h sem bot e 60,1 h com bot, então rejeita H_0
Mann-Whitney	U = 204	0,0003	Um PR sem bot demorou mais em 23% dos pares, contra 50% esperados sob H_0, então rejeita H_0

5. Erro tipo I (Q1 e Q3)

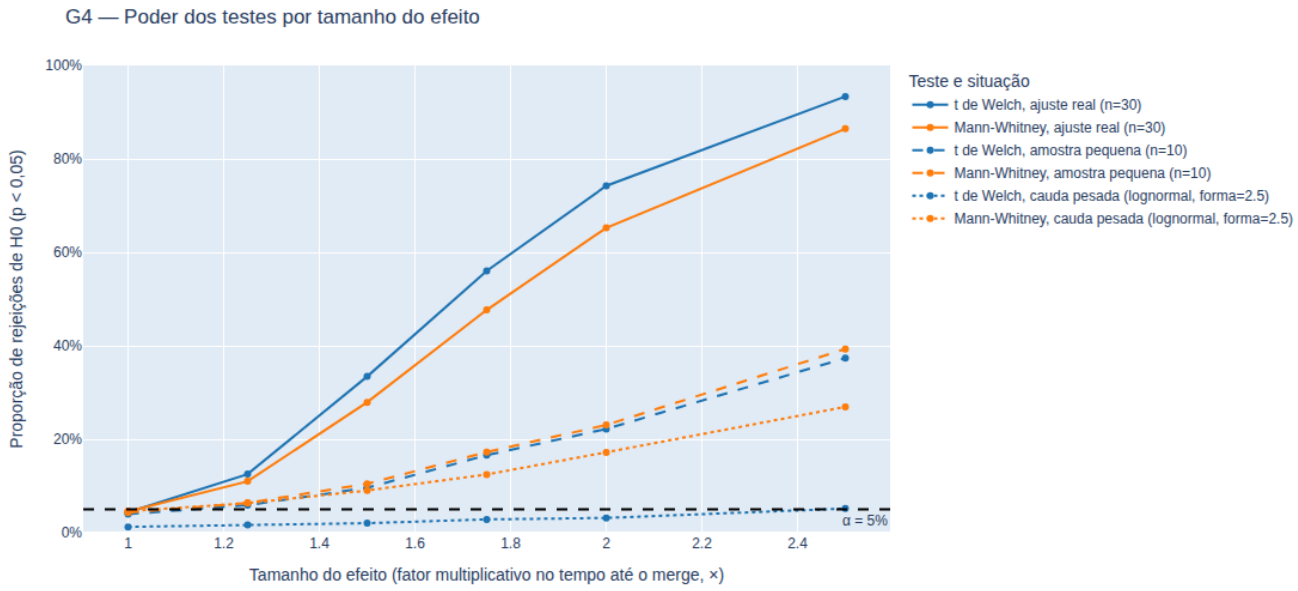


Situação	t de Welch	Mann-Whitney
Ajuste real (n = 30)	4,3%	4,6%
Amostra pequena (n = 10)	4,0%	4,3%
Cauda pesada	**1,2%**	4,6%

A margem da simulação é de ±0,4 ponto percentual.

- **Dados parecidos com os reais:** os dois testes ficam perto de 5%, com o t de Welch um pouco conservador.
- **Cauda pesada:** o t de Welch fica bem conservador, porque os outliers inflam o desvio padrão e encolhem a estatística t.
- **Mann-Whitney:** usa só a ordem dos valores e fica estável em todas as situações.

6. Poder (Q2 e Q3)



Proporção de rejeições de H_0 (α = 0,05):

Fator	Ajuste real, Welch	Ajuste real, Mann-Whitney	n = 10, Welch	n = 10, Mann-Whitney	Cauda pesada, Welch	Cauda pesada, Mann-Whitney
1,00	4,3%	4,6%	4,0%	4,3%	1,2%	4,6%
1,25	12,5%	11,0%	5,9%	6,4%	1,7%	6,3%
1,50	33,4%	27,9%	9,6%	10,5%	2,0%	9,0%
1,75	56,0%	47,7%	16,6%	17,2%	2,9%	12,5%
2,00	**74,2%**	65,2%	22,2%	23,1%	3,2%	**17,2%**
2,50	93,4%	86,5%	37,4%	39,3%	5,2%	**26,9%**

- **Dados parecidos com os reais:** o t de Welch tem mais poder em todos os fatores.
- **Cauda pesada:** a vantagem muda de lado. O t de Welch quase não detecta o efeito, e o Mann-Whitney detecta cerca de 5 vezes mais.
- **Amostra pequena (n = 10):** os dois testes empatam, com poder de no máximo 39%.

Mudando α para 0,01

Mesma simulação, com a mesma semente:

Situação e fator	t de Welch, α = 0,05	t de Welch, α = 0,01	Mann-Whitney, α = 0,05	Mann-Whitney, α = 0,01
Ajuste real, fator 1 (erro tipo I)	4,3%	0,6%	4,6%	0,9%
Ajuste real, fator 2	74,2%	45,5%	65,2%	40,2%
Cauda pesada, fator 2,5	5,2%	0,4%	26,9%	10,9%

Com α = 0,01, a linha de referência do G3 desce para 1%, e as barras acompanham. No G4, todas as curvas caem: o teste erra menos quando não há efeito, mas deixa passar mais efeitos reais.

Poder com o tamanho de amostra real

No efeito observado nos dados reais (média 1,68 vez maior), a simulação dá estes valores:

PRs por grupo	t de Welch	Mann-Whitney
30, a amostra coletada	50%	42%
60	82%	71%
80	92%	84%

- **Com a amostra coletada:** a chance de detectar o efeito era praticamente um cara ou coroa. Isso explica por que os dois testes discordaram nos dados reais.
- **Para 80% de poder:** seriam necessários cerca de 60 PRs por grupo no t de Welch e cerca de 75 no Mann-Whitney. Isso é viável no HPX, que tinha 209 e 159 PRs elegíveis.

7. Dados reais

Teste	Estatística	p-valor	Tamanho do efeito	Conclusão
t de Welch	t = 2,05	0,046	Diferença das médias de +27,6 h (IC 95%: 0,5 a 54,8 h); d de Cohen = 0,53, médio	Rejeita H_0
Mann-Whitney	U = 570	0,077	Um PR com bot demora mais em 63% dos pares; rank-biserial r = 0,27, pequeno	Não rejeita H_0

No Mann-Whitney, U é o número de pares em que o PR com bot demorou mais.

- **Direção:** os testes discordam na decisão, mas apontam na mesma direção. Os PRs abertos depois do bot demoraram mais.
- **Importância prática:** a diferença média é de pouco mais de um dia, mas o intervalo de confiança é largo, de quase zero a mais de dois dias.
- **Mediana:** as medianas diferem só 6 h, então parte da diferença vem de poucos PRs muito demorados.

8. Expectativa × resultado e recomendação

	O que esperávamos	O que encontramos
Erro tipo I	Os dois perto de 5%, com o t de Welch conservador na cauda pesada	Confirmado
Poder com dados realistas	Mann-Whitney com mais poder	**Não confirmado:** o t de Welch tem mais poder
Cauda pesada	Maior vantagem do Mann-Whitney	Confirmado
Amostra pequena	Diferença menor entre os testes	Confirmado

A expectativa sobre o poder errou porque os tempos reais seguem uma Gamma de forma perto de 1: a cauda é longa, mas não pesada. Nesse caso, a média resume bem uma mudança de escala, e o Mann-Whitney perde informação ao usar só a ordem dos valores. É o que o enunciado antecipa: o teste não paramétrico não ganha sempre que os dados não são normais.

Recomendação: usar o **t de Welch** neste cenário. Ele mantém o erro tipo I abaixo de 5% e tem mais poder com dados como os do HPX. A escolha mudaria para o **Mann-Whitney** nestes casos:

- **Cauda muito pesada:** por exemplo, sem o limite de 30 dias da coleta, PRs que levam meses dominariam a média.
- **Pergunta sobre o PR típico:** se o interesse for o PR típico, e não o tempo médio.

9. Limitações

- **Desenho antes × depois.** Os períodos diferem em mais do que o bot, como nos autores ativos e no tipo de PR. O estudo indica qual teste usar, mas não prova que o bot mudou o tempo até o merge.
- **Observações não totalmente independentes.** O grupo com bot tem 9 autores, e 3 deles somam 20 dos 30 PRs. Os dois testes assumem observações independentes.
- **Cauda cortada.** O limite de 30 dias remove os PRs mais demorados, então a assimetria real é maior que a da amostra.
- **Um único repositório, com 30 PRs por grupo.** O poder para o efeito observado era de cerca de 50%.
- **Situações simuladas.** A cauda pesada (σ do log = 2,5) é um caso extremo, escolhido para testar a violação de pressupostos, e não para imitar o HPX.

10. Como reproduzir

Dentro da pasta `LAB04`, com as dependências do `requirements.txt` instaladas:

```
python -m lab04
```

O comando roda o estudo inteiro em poucos segundos, com a semente 42, e gera `dashboard/index.html`. Os testes automatizados rodam com `python -m pytest`. A coleta dos dados reais é separada (`python -m lab04.coleta`), porque depende da API do GitHub. A amostra usada está versionada em `dados/prs.csv`.